Agent 应用代码仓 CI/CD 能力构建指导

基于 G1–G6 六级质量防线与双看板的实施方案

静态检查 · 分层用例 · 灰度防线 · CI/CD 看板 · 生态健康度看板



2026-10-14

建设目标与设计原则

目标　**在开发者本地、PR、主干、每日任务、版本发布和生产灰度之间建立连续验证链路，并用看板保留可追溯证据。**

01	**本地与 CI 同源**	统一通过 Pre-commit 和仓库脚本执行，减少“本地通过、CI 失败”。
02	**按风险逐级加深**	越接近发布，真实模型、真机、故障注入和长时间运行越完整。
03	**快速检查前置**	G1 控制在 5–12 分钟，PR Ready 的 G2 控制在 15–30 分钟。
04	**失败立即改变状态**	PR 阻断、主干标红、RC 停止生成、灰度停止扩量。
05	**结果可下钻**	每个指标能定位到工作流、用例、日志、环境和责任人。

静态检查工具链

检查范围	推荐工具	门禁作用
Python 代码质量	Ruff Check	错误、警告、导入和命名规范
Python 代码格式	Ruff Format	统一格式，支持自动修复
Python 类型检查	mypy	检查类型契约与未标注函数
通用文件格式	pre-commit-hooks	YAML/JSON/TOML、行尾和空白
拼写与文档	Typos + Markdownlint CLI2	拼写和 Markdown 规范
Shell 脚本	ShellCheck	Shell 语法和常见风险
GitHub Actions	Actionlint	Workflow 语法和表达式
统一执行入口	Pre-commit	本地 Commit 与 CI 使用同一配置

本地与 CI 的统一执行入口

开发者本地

PR 门禁

IDE / git commit

保存时检查或 Commit 前执行

Pre-commit

统一编排全部静态检查

GitHub Actions

全量执行并生成 Check

关键配置

.pre-commit-config.yaml	固定 Hook 版本；定义 Ruff、mypy、Typos、Actionlint、Markdownlint、ShellCheck。
pyproject.toml	集中配置 Ruff、mypy、Typos 和 pytest，Python 目标版本为 3.10。
执行策略	本地允许安全自动修复；CI 以结果验证为主，修改后要求开发者重新提交。

G1–G6 六级质量防线

G1	G2	G3	G4	G5	G6
提交与 PR 基础门禁	PR Ready 防线	集成与合入防线	Nightly 全量防线	Release Candidate	发布后灰度防线
<5 min	<15 min	<30 min	<3 h	视实际情况而定	持续监控

资源真实性与验证深度逐级提高

Mock / Scripted Model

模拟器 / Sandbox

真实模型 / 真机 / 生产灰度

PR 合入前：G1 与 G2

G1 提交与 PR 基础门禁

触发	Commit 前；PR 创建、更新或重新打开
覆盖	UT、规范、类型安全、敏感信息、可编译性、核心逻辑、确定性 Agent 行为
环境	本地与 CPU Runner；Mock；Scripted Model
失败	**PR 标红，不允许进入 Ready**

G2 PR Ready 防线

触发	Draft 转 Ready，或添加 ready-for-review 标签
覆盖	UT 与基础 E2E；关键业务链路、模拟器交互、安全与隐私 Smoke
环境	CI Runner；HarmonyOS 模拟器；Sandbox；固定或轻量模型
失败	**阻止批准和合入；必须修复或明确豁免**

目录约定：UT 与组件源码保持镜像关系；基础 E2E 位于 tests/e2e/basic 与 tests/e2e/feature。

主干合入后：G3 集成防线



失败处置

1. **主分支标红并暂停 Release**
2. 严重问题执行 Revert 或关闭问题功能
3. 结果关联首次失败提交、日志、模型和设备

执行条件

CI Runner、模拟器、Sandbox、受限真实模型，以及至少一台真机或设备云。

建议时长：<30 分钟

测试目录：tests/e2e/feature_expand/

每日运行：G4 Nightly 全量防线

覆盖范围

1. 全功能 E2E
2. Agent 任务质量
3. 性能与稳定性
4. 可靠性与异常恢复
5. 设备和模型兼容性

执行环境

真机矩阵
HarmonyOS 模拟器
Sandbox 和真实模型
故障注入环境

建议时长 <3 小时

输出与处置

- 生成报警与趋势报告
- 展示失败用例及直接链接
- 识别性能退化和质量漂移
- **失败阻止产生 Release Candidate**

低峰定时执行；重大架构修改后支持手动触发。

版本发布前：G5 Release Candidate 防线

最终产物

安装、升级、签名和 Release 配置

全量验收

功能、安全、隐私与设备兼容

非功能验证

性能、稳定性和可靠性

发布决策

质量报告、风险评审和签字放行

运行条件	**最终签名环境、Release 配置、真机矩阵和预发布后端。**
建议时长	**视实际情况而定，在版本发布前数日完成。**
不可豁免	**P0/P1、安全、升级和签名问题必须修复，流水线直接阻止发布。**

测试目录：tests/dfx/stability/ · tests/dfx/reliability/

发布后：G6 灰度防线



每个阶段观察数小时至 1 天

稳定性	任务质量	成本	隐私	回滚能力
Crash、ANR、异常恢复	Agent 完成率与人工反馈	模型与 Tool Provider 消耗	脱敏遥测和敏感信息风险	Feature Flag、备用模型和服务

异常处置：自动停止扩量，关闭问题功能，切换备用模型或服务，必要时执行版本回滚。

六级防线的环境与用例映射

阶段	主要环境	主要目录或资产	目标时长
G1	本地、CPU Runner、Mock、Scripted Model	tests/{component}/	<5 min
G2	CI Runner、HarmonyOS 模拟器、Sandbox	tests/e2e/basic/、feature/	<15 min
G3	模拟器、真实服务、受限模型、真机	tests/e2e/feature_expand/	<30 min
G4	真机矩阵、真实模型、故障注入	tests/dfx/perf/ 与全量 E2E	<3 h
G5	签名环境、Release 配置、预发布后端	tests/dfx/stability/、reliability/	视实际情况而定
G6	生产灰度、遥测、Feature Flag	线上观测规则与回滚脚本	持续监控

用例应通过标签选择执行层级，避免复制同一测试逻辑。

双看板的数据链路

GitHub

PR、Issue、Star、Fork、Contributor

CI/CD

Workflow、Job、耗时、状态、日志

测试报告

JUnit、覆盖率、性能和失败用例

发布系统

RC、Release、灰度阶段和回滚

采集与标准化

统一 repo、commit、PR、workflow、case、timestamp 标识

CI/CD 看板

G1–G6 成功率、耗时、结果、覆盖率、性能

生态健康度看板

Star、Fork、Contributor、PR、Issue

数据要求：保留事件快照和原始链接；看板指标必须能够下钻到 PR、用例、日志和 Issue。

CI/CD 看板设计

总览

G1–G6 成功率、耗时、执行结果统计

门禁 PR

Ready PR 与合入 PR 的通过率、失败原因

Daily

每日验证结果、通过率、失败用例和直接链接

Release

功能、性能、稳定性、可靠性分类结果

性能专项

用例执行状态、指标趋势、退化文字告警

UT 覆盖率

总体覆盖率、目录覆盖率、时间趋势

统一筛选：时间范围、分支、G1–G6、组件、用例类型、执行环境、失败类型和责任团队

CI/CD 看板设计


CI/CD 质量看板
概览
构建与测试
性能分析
发布管理
报告中心
2024-11-01 ~ 2024-11-30
1天
7天
30天
筛选条件
时间范围
2024-11-01 ~ 2024-11-30
分支（Branch）
main
组件（Component）
全部
环境（Environment）
全部
应用筛选
CI/CD 质量看板
构建历史
测试用例
性能分析
发布记录
配置管理
G1–G6 总览
G1
代码检查
98.7%
1m 12s
G2
单元测试
96.3%
3m 28s
G3
集成测试
89.5%
6m 31s
G4
安全扫描
99.1%
2m 08s
G5
构建镜像
98.4%
4m 12s
G6
部署验证
92.0%
5m 46s
成功率
95.2%
+1.8%
P95 耗时
8m 17s
-12.6%
失败用例
12
-38.5%
门禁 PR
8
-27.3%
Nightly
27 / 28
96.4%
Release
4
100%
通过 / 失败 趋势
通过
失败
120
90
60
30
0
11-01
11-04
11-07
11-10
11-13
11-16
11-19
11-22
11-25
11-28
P95 耗时
20m
15m
10m
5m
0m
6.3m
7.1m
12.4m
8.9m
6.7m
14.6m
G1 代码检查
G2 单元测试
G3 集成测试
G4 安全扫描
G5 构建镜像
G6 部署验证
失败用例
用例名称 组件 失败原因 发生时间 链接
1 test_agent_memory_persistenc agent-core 断言不匹配 2024-11-28 10:21 查看
2 test_tool_call_timeout agent-tools 超时（>30s） 2024-11-27 22:14 查看
3 test_rag_retrieval_accuracy agent-rag 返回结果不符合预期 2024-11-27 18:03 查看
4 test_streaming_response agent-runtime 连接中断 2024-11-26 11:37 查看
5 test_permission_denied agent-tools 403 权限错误 2024-11-25 16:09 查看
性能趋势
平均耗时
P95 耗时
20s
15s
10s
5s
0s
11-01
11-04
11-07
11-10
11-13
11-16
11-19
11-22
11-25
11-28
UT 覆盖率
覆盖率
agent-core 92.1%
agent-tools 85.6%
agent-rag 78.4%
agent-runtime 88.9%
agent-ui 71.2%
agent-common 95.3%
0%
25%
50%
75%
100%

项目生态健康度看板设计

社区生态概览

Star	Fork	Contributor	PR	Issue
数量与增长曲线	数量与增长曲线	内部 / 外部数量与增长	数量、状态与增长曲线	数量、状态与增长曲线

Issue 专题

Open / Closed 数量、首次响应时间、解决周期、长期未解决数量。

PR 专题

按当日、一周、一个月查看 Open、Merged、Closed；默认选择一周。

建议补充：外部贡献者占比、PR 首次评审时间、Issue P50/P90 解决周期、贡献者留存率。

项目生态健康度看板示例



看板指标口径与告警

用例成功率	通过用例数 / 有效执行用例数；取消与基础设施故障单列
流水线耗时	同时展示排队、执行和总耗时；使用 P50 与 P95
PR 通过率	进入 Ready 或合入状态的 PR 中，通过对应门禁的比例
Issue 解决周期	Issue 创建到关闭；重开 Issue 单独统计
性能变化	**同环境、同数据、同版本配置对比；超过阈值输出文字告警**
覆盖率	总覆盖率与目录覆盖率并列；保留时间趋势

告警必须包含：当前值、基线、阈值、影响范围、证据链接和责任人。

实施路线图与验收标准

阶段 1	阶段 2	阶段 3	阶段 4
静态门禁	**G1–G3**	**G4–G5**	**G6 与看板**
Pre-commit、本地与 CI 同源	PR 与主干链路跑通	全量测试、RC 与性能基线	灰度、告警和生态数据

验收标准

- ✓ 静态检查可在 IDE、本地 Commit 和 CI 执行
- ✓ G1–G6 触发条件、环境和失败处置可验证
- ✓ CI/CD 看板覆盖总览、PR、Daily、Release、性能和 UT
- ✓ 生态看板覆盖 Star、Fork、Contributor、PR 和 Issue
- ✓ **任何失败结果可下钻到用例、日志和责任人**